🎯 Plan de Formation Autodidacte — ML · Data Science · Data Analyst

> **Profil** : Développeur informatique, licence info ~10 ans, maths partiellement oubliés
> **Disponibilité** : 3 à 6h / semaine
> **Objectif** : Acquérir des compétences solides et progressives dans les 3 domaines
> **Format de suivi** : Étape par étape, validation avant passage à la suivante

📊 Estimation des durées globales

Niveau	Heures totales estimées	Durée à 3h/sem	Durée à 6h/sem
Notions (comprendre de quoi on parle)	~50h	~4 mois	~2 mois
Débutant (premiers projets fonctionnels)	~150h supplémentaires	+1 an	+6 mois
Intermédiaire (projets réels, autonomie)	~300h supplémentaires	+2 ans	+1 an
Expert (maîtrise avancée, production)	~500h supplémentaires	+3 ans	+18 mois

> ⚠️ Ces durées sont des estimations moyennes. Elles varient selon ta régularité et ton engagement sur les projets pratiques.

🗺️ Vue d'ensemble des phases

```
PHASE 0 — Socle commun (maths + Python)          ← On commence ici
PHASE 1 — Data Analyst
PHASE 2 — Data Science
PHASE 3 — Machine Learning
PHASE 4 — Projets intégrateurs & Portfolio
```

> Les phases 1, 2 et 3 sont progressives et interdépendantes.
> La Phase 0 est **obligatoire** et commune aux 3 domaines.

🔷 PHASE 0 — Socle commun fondamental

Durée estimée : ~60h (4 à 5 mois à 3h/sem)
Objectif : Avoir les bases solides en maths et Python pour aborder les 3 domaines

Étape 0.1 — Remise à niveau Mathématiques (≈25h)

- Algèbre linéaire : vecteurs, matrices, produit matriciel, transposition
- Statistiques descriptives : moyenne, médiane, écart-type, variance, distribution
- Probabilités : loi des grands nombres, loi normale, loi de Bayes
- Calcul différentiel (bases) : dérivées, gradient, notion d'optimisation

Étape 0.2 — Python pour la Data (≈25h)

- Rappels Python : structures de données, fonctions, classes, fichiers
- NumPy : tableaux, opérations vectorisées
- Pandas : DataFrames, manipulation, nettoyage, filtres, agrégations
- Matplotlib / Seaborn : visualisations de base

Étape 0.3 — Environnement de travail (≈10h)

- Jupyter Notebook / JupyterLab
- Git & GitHub (versionner ses notebooks)
- Conda / virtualenv (gestion d'environnements)

🔶 PHASE 1 — Data Analyst

Durée estimée : ~80h (6 à 7 mois supplémentaires à 3h/sem)
Prérequis : Phase 0 validée

Étape 1.1 — Analyse exploratoire des données (EDA) (≈20h)

- Comprendre et nettoyer un jeu de données
- Identifier les valeurs manquantes, outliers
- Visualisations avancées (distributions, corrélations, heatmaps)

Étape 1.2 — SQL pour l'analyse (≈20h)

- SELECT, WHERE, GROUP BY, HAVING, JOIN
- Sous-requêtes, fenêtres (window functions)
- Pratique sur des bases réelles (ex: SQLite, PostgreSQL)

Étape 1.3 — Statistiques appliquées à l'analyse (≈20h)

- Tests statistiques : t-test, chi^2, ANOVA
- Corrélation vs causalité
- Introduction aux intervalles de confiance et p-values

Étape 1.4 — Visualisation & Reporting (≈20h)

- Tableaux de bord avec Plotly / Dash ou Power BI (au choix)
- Raconter une histoire avec des données (data storytelling)
- Projet fil rouge : analyser un dataset réel et produire un rapport complet

🟠 PHASE 2 — Data Science

Durée estimée : ~100h (8 à 9 mois supplémentaires à 3h/sem)
Prérequis : Phase 1 validée

Étape 2.1 — Feature Engineering (≈20h)

- Encodage des variables catégorielles
- Normalisation / standardisation
- Création de nouvelles features, sélection de features

Étape 2.2 — Introduction au Machine Learning (≈30h)

- Concepts : supervisé / non supervisé, overfitting, underfitting
- Scikit-learn : pipeline, train/test split, cross-validation
- Premiers modèles : régression linéaire, régression logistique, k-NN

Étape 2.3 — Évaluation des modèles (≈20h)

- Métriques : accuracy, precision, recall, F1, ROC-AUC, RMSE
- Matrice de confusion
- Comparaison et sélection de modèles

Étape 2.4 — Projet Data Science complet (≈30h)

- Collecte → nettoyage → exploration → modélisation → évaluation → présentation
- Projet fil rouge sur Kaggle ou dataset réel

🔴 PHASE 3 — Machine Learning avancé

Durée estimée : ~150h (1 an supplémentaire à 3h/sem)
Prérequis : Phase 2 validée

Étape 3.1 — Algorithmes supervisés avancés (≈30h)

- Arbres de décision, Random Forest, Gradient Boosting (XGBoost, LightGBM)
- SVM (Support Vector Machines)
- Hyperparameter tuning (GridSearch, RandomSearch, Optuna)

Étape 3.2 — Apprentissage non supervisé (≈25h)

- Clustering : K-Means, DBSCAN, hierarchique
- Réduction de dimensionnalité : PCA, t-SNE, UMAP

Étape 3.3 — Deep Learning (introduction) (≈40h)

- Réseaux de neurones : perceptron, rétropropagation, fonctions d'activation
- Frameworks : TensorFlow / Keras ou PyTorch
- CNN (images), RNN / LSTM (séquences)

Étape 3.4 — MLOps & mise en production (≈30h)

- Sauvegarder et charger des modèles (joblib, pickle, ONNX)
- Créer une API de prédiction (FastAPI)
- Introduction à MLflow pour le tracking d'expériences

Étape 3.5 — Projet ML complet de bout en bout (≈25h)

- De la donnée brute au modèle déployé
- Documenter, versionner, présenter

🟢 PHASE 4 — Projets intégrateurs & Portfolio

Durée estimée : ~80h (6 mois supplémentaires à 3h/sem)
Prérequis : Phases 1, 2 et 3 validées

Étape 4.1 — Construire son portfolio GitHub (≈20h)

- 3 projets minimum bien documentés (README, notebooks propres)
- Un projet par domaine (analyse, science, ML)

Étape 4.2 — Kaggle & compétitions (≈30h)

- Participer à des compétitions pour affronter des cas réels
- Lire et analyser des notebooks publics de top participants

Étape 4.3 — Veille technologique & spécialisation (≈30h)

- Choisir une spécialisation (NLP, vision, séries temporelles…)
- Suivre les tendances : papers, blogs, podcasts

📌 Ressources recommandées (gratuites en priorité)

Domaine	Ressource	Lien
Maths	3Blue1Brown (YouTube)	youtube.com/3blue1brown
Maths	Khan Academy	khanacademy.org
Python/Data	Kaggle Learn	kaggle.com/learn
ML	fast.ai	fast.ai
ML	Andrew Ng — ML Specialization (Coursera)	coursera.org
SQL	SQLZoo / Mode Analytics	sqlzoo.net
Pratique	Kaggle Datasets & Competitions	kaggle.com

🚀 Suivi de progression

Phase	Étape	Statut	Date validation
Phase 0	0.1 Maths	⬜ À faire	—
Phase 0	0.2 Python Data	⬜ À faire	—
Phase 0	0.3 Environnement	⬜ À faire	—
Phase 1	1.1 EDA	⬜ À faire	—
Phase 1	1.2 SQL	⬜ À faire	—
Phase 1	1.3 Stats appliquées	⬜ À faire	—
Phase 1	1.4 Visualisation	⬜ À faire	—
Phase 2	2.1 Feature Engineering	⬜ À faire	—
Phase 2	2.2 Intro ML	⬜ À faire	—
Phase 2	2.3 Évaluation modèles	⬜ À faire	—
Phase 2	2.4 Projet DS	⬜ À faire	—
Phase 3	3.1 Algos supervisés avancés	⬜ À faire	—
Phase 3	3.2 Non supervisé	⬜ À faire	—
Phase 3	3.3 Deep Learning	⬜ À faire	—
Phase 3	3.4 MLOps	⬜ À faire	—
Phase 3	3.5 Projet ML	⬜ À faire	—
Phase 4	4.1 Portfolio	⬜ À faire	—
Phase 4	4.2 Kaggle	⬜ À faire	—
Phase 4	4.3 Veille & spécialisation	⬜ À faire	—

Document généré le 22/03/2026 — Mis à jour à chaque validation d'étape